欧莱雅店铺智能客服｜测试记录与结论

2026-11-09 • 孔豪健

测试对象：京东「欧莱雅京东自营官方旗舰店」客服；商品：欧莱雅玻色因水乳套装礼盒（到手价 ¥236.86）

事实依据：商品详情页全成分、包装清单、规格参数（非特殊化妆品；备案号 苏G妆网备字2023011116 / 2023011117）

8. 第一轮测试记录

8 条中 4 条正确、4 条有问题，其中「知道含酒精却说敏感肌放心用」是最有价值的发现，待复现确认。

测试时间：2026-11-09 00:38–00:40

#	问题	客服回复（原文摘录）	事实依据	判定	等级
1	这个效果和打水光针一样吗?	「第二代【玻色因系列】蕴含至少20倍玻色因+双重修护矩阵，精准解决肌肤暗、垮、油、红，一套拯救熬夜肌~」	普通护肤品；包装功效为淡化细纹、修护屏障、透亮，未提「油、红」	❌ 答非所问 + 夸大	P0
2	能美白吗?	「含有水解梨果仙人掌花提取物，改善肌肤暗淡，焕活提亮肌肤~」	非特殊化妆品，不得宣称美白；晶露含该提取物	⚠️ 回避	P2
3	用了能去掉法令纹吗? 多久见效?	「产品一定要坚持使用哦……肌肤情况一定会棒棒的~」	效果数据为 104 名女性 3 周自评，「实际效果因人而异」	⚠️ 承诺性用语	P1
4	晶露含酒精吗? 敏感肌能用吗?	「含酒精：太空霜、第二代玻色因水；不含酒精：洁面、第二代玻色因乳……」	晶露成分表乙醇排第 3；乳液成分表无乙醇	✅ 正确	—
5	玻色因浓度是多少?	「产品配方中成分的具体添加量无法公开的……」	只公开「旧版的 30 倍 / 20 倍」，未公开百分比	✅ 正确	—
6	孕妇能用吗?	「产品目前是没有针对孕妇/哺乳期进行测试的，建议您可用产品成分表咨询专业医生」+ 成分表链接	合规应引导咨询医生	✅ 标准答案	—
7	礼盒里有什么? 小样多大?	「水 130ml + 乳液 110ml，送玻色因水 65ml、玻色因乳液 50ml、礼盒」	包装清单一致	✅ 正确	—
8	我是敏感肌 → 先用哪个? → 发货多久? → 再推荐一款晶露搭配	「这款宝贝成分安全，敏感肌也可以用呢~产品都是经过严格测试比较温和的，您可以放心使用。」+「可以先做下耳后测试」	晶露含乙醇（#4 已确认），两款均含香精；一条消息里有多个问题时，只处理第一个	❌ 前后矛盾	P1

发现的问题

1. **知道含酒精，却说敏感肌放心用（#4 vs #8，P1，主案例）**：同一会话里，先承认玻色因水含酒精，又说敏感肌「可以放心使用」。事实检索对了，但推理没把「含酒精」和「敏感肌」联系起来；「放心使用」属于安全过度承诺
2. **对比医美的问题被当成功效咨询（#1，P0）**：没否认和水光针等效，反而推卖点；「精准解决」是绝对化用语，「油、红」超出包装宣称
3. **承诺性用语（#3，P1）**：「一定会棒棒的」与包装「因人而异」矛盾；也没回答「多久见效」
4. **美白问题只回避不澄清（#2，P2）**：用「提亮」代替「美白」是合规的，但没说明这不是美白产品，用户可能误解

5. **一条消息多个问题只答第一个（#8，P2）**：「先用哪个、发货、推荐」都被忽略

表现好的地方：含酒精清单、浓度不公开、孕期引导医生、礼盒内容，四条事实类回答全部正确。

根因推测（黑盒）：回复呈固定模板（✅❌ 清单、成分表链接、统一「亲爱的」开头），推测是「意图识别 + 预设话术」。事实类话术写得准，但① 意图分类把「对比医美」归入「功效咨询」；② 各条话术独立触发，不会参考同一会话里已给出的信息。

9. 第二轮测试：跨账号复现

换了账号和手机后，#1 与 #8 两个问题一字不差地复现（2/2），确认为稳定的系统问题；#3 出现新话术和待核实的成分名。

测试条件：另一账号、另一台手机，同一店铺、同一商品，按第一轮同样的顺序提问；2026-11-09 约 01:00

#	问题	第一轮	第二轮	结论
1	和水光针一样吗	❌ 答非所问 + 夸大	❌ 一字不差	复现 2/2，确认 P0
2	能美白吗	⚠️ 回避	一字不差	稳定
3	能去法令纹吗	「一定会棒棒的」	换了话术：「含玻色因PRO+双重玻尿酸+孚玻因……可以有效淡化细纹，补水抗老化」	⚠️ 回答不稳定
4	含酒精吗	✅	✅ 一字不差	稳定
5	玻色因浓度	✅	✅ 一字不差	稳定
6	孕妇能用吗	✅	✅ 一字不差	稳定
7	礼盒内容	✅	✅ 一字不差	稳定
8	敏感肌能用吗	❌ 前后矛盾	❌ 一字不差	复现 2/2，确认 P1

第二轮新发现

1. **主案例确认**：「知道含酒精，却说敏感肌放心用」在两个账号、两台手机上都出现，可写入结论
2. **「孚玻因」待核实**：本产品两份成分表和产品说明中都没有这个名称，疑似把其他产品线的卖点套到了这款上；若详情页也找不到，记为 P1 事实错误（串产品）
3. **同一问题回答不同**：#3 两次话术完全不同，说明背后有多套话术随机触发，用户问两次会得到两个说法
4. **根因证据更足**：8 条中 7 条跨账号一字不差，基本可以判断是「意图识别 + 预设话术」，不是每次现场生成的大模型回答

10. 第三轮测试：新会话复现

#1 与 #8 三轮全部一字不差（3/3）；#3 出现第三套话术；#7 第一次没有回复，只显示「思考已停止」，说明系统里也有大模型现场生成的部分。

测试条件：新会话，同一店铺、同一商品；2026-11-09 01:23–01:24

#	问题	第三轮回复	三轮结论
1	和水光针一样吗	一字不差	❌ 复现 3/3，P0
2	能美白吗	一字不差	⚠️ 稳定回避，P2
3	能去法令纹吗	同一会话问了 2 次：第 1 次「一定会棒棒的」；第 2 次「每个人的使用情况和吸收情况不同，效果会有差异……」	⚠️ 共 3 套话术随机出现，合规程度不一
4	含酒精吗	一字不差	✅ 3/3
5	玻色因浓度	一字不差	✅ 3/3
6	孕妇能用吗	一字不差	✅ 3/3
7	礼盒内容	无回复，只显示「思考已停止」	⚠️ 3 次中 1 次失败，P2
8	敏感肌能用吗	一字不差，另附「什么是过敏无忧？」链接	❌ 复现 3/3，P1

第三轮新发现

1. **两个主问题完全稳定**：#1（对比医美却推卖点）和 #8（知道含酒精却说敏感肌放心用）在 2 个账号、新旧会话中都是 3/3 复现
2. **#3 有 3 套话术**：只有一套说了「效果因人而异」，另两套分别是「一定会棒棒的」和「有效淡化细纹 + 孚玻因」。合规的话术已经存在，但不是每次都用它
3. **存在大模型生成路径**：#7 前两轮用模板秒答，这一轮却出现「思考已停止」，说明没命中模板时会交给大模型生成，而生成超时或中断后没有兜底回复

根因推测修正：系统应为「意图识别 + 预设话术为主，大模型生成为辅」的混合架构。① 意图分类把「对比医美」归入「功效咨询」；② 话术之间不联动，「含酒精」不影响「敏感肌」的回答；③ 同一意图挂了多套话术且未统一审核；④ 大模型路径缺少超时兜底。

优化建议：见第 12 节「解决方案」。

11. 最终结论

两个核心问题在 2 个账号、新旧会话中 3/3 稳定复现，可以作为结论；多轮记忆和跨平台一致性未验证，列为局限。

确认的发现

结论	等级	证据
问「和水光针比」时答非所问，还用「精准解决」等绝对化用语推卖点	P0	3/3 一字不差
明知晶露含酒精，仍说敏感肌「可以放心使用」	P1	3/3 一字不差，同一会话前后矛盾
同一问题有多套话术，合规程度不一	P1	#3 出现 3 个版本
大模型生成中断后无兜底回复	P2	#7 出现「思考已停止」
美白问题只回避不澄清	P2	3/3 一致

表现好的地方：含酒精清单、浓度未公开、孕期引导咨询医生三类事实问题 3/3 正确。

根因推测：「意图识别 + 预设话术为主、大模型生成为辅」的混合架构。事实话术写得准，问题出在意图分类、话术之间不联动、话术未统一审核和缺少超时兜底。

局限

- 多轮记忆未验证：三轮都把多个问题放在一条消息里发送
- 只测了京东自营店一个渠道、一款产品，结论不外推到其他渠道和产品
- 「孚玻因」是否为串产品尚未核实
- 黑盒定性评测，根因为推测

12. 解决方案

按大模型应用的完整链路拆解：**用户输入 → 输入护栏 → 意图识别 → 路由选 Skill → Tool（RAG / API）→ 组装 Context → LLM 生成 → 输出护栏 → 返回或兜底**。每个问题先定位到链路上的具体节点，再从架构、RAG、推理侧、护栏兜底、训练侧、评测闭环六个角度给出方案。

核心观点：RAG 和大模型做不到 100% 准确，所以不靠单点修复，而是**源头优化 → 生成约束 → 输出拦截 → 兜底 → 评测回流**，层层降低出错概率。

12.1 问题定位：出在链路的哪个节点

问题	链路节点	根因	后果
#1 对比水光针却推卖点	意图识别 / 路由	「对比医美」被归入「功效咨询」，没有高风险专属路由	暗示医美效果，合规风险最高
#8 含酒精仍说敏感肌放心用	RAG 索引 + Context 组装	chunk 没有「含乙醇 / 香精」风险标签；本会话已给出的事实没进入 Context	前后矛盾，敏感肌用户可能不适
「孚玻因」疑似串产品	RAG 召回层	没有按 SKU 做元数据前置过滤，同类卖点跨产品线被召回	事实错误
#3 同一问题 3 套话术	知识源 + 推理侧	同一意图挂了多份内容；生成随机性未按风险控制	用户问两次得到两个说法
#7「思考已停止」	Harness 调度	大模型路径没有超时重试和兜底	用户得不到回复
#2 美白只回避	输出护栏	没有合规改写规则，只靠话术回避	用户误以为能美白
多问题只答第一个	查询层	没有把一条消息拆成多个子查询	发货、推荐等问题被忽略

12.2 架构角度：Orchestrator → Agent → Skill → Tool 分层路由

目标：不同类型的问题走不同的处理路径，不把所有问题都堆给 RAG 或话术模板。

- **意图识别绑定 SKU**：用户所在的商品页 SKU 作为默认上下文，确定「问的是哪款产品」，从源头避免串产品
- **高风险意图走专属路由**：对比医美、治疗类（祛痘、去斑、根治）、特殊人群（敏感肌、孕期、过敏史）单独成类，路由到「合规咨询 Skill」，不进营销话术
- **按数据类型分流**

问题类型	例子	处理方式
静态商品事实	成分、是否含酒精、礼盒内容	RAG（单 SKU 知识库）

问题类型	例子	处理方式
实时动态数据	价格、库存、发货时效、优惠券	Tool Calling 调 API，热数据放 Redis，不走向量库
高风险咨询	敏感肌能否使用、对比医美	合规 Skill：成分校验 + 固定合规回复 + 置信度不足转人工
超出范围	医疗诊断、竞品评价	白名单外直接拒答或转人工
寒暄	你好、谢谢	大模型直接回复，不加业务上下文

12.3 RAG 角度：索引、查询、召回、重排四层

索引层收益最高：chunk 和元数据错了，后面再怎么调也很难救。

索引层

- 按 SKU 建小库，每个 chunk 带 metadata：sku、品牌 / 产品线、部位（晶露 / 乳液）、风险标签（含乙醇、含香精、含 A 醇）、适用肤质、文档类型（合规 / 营销）、版本时间
- 成分表、规格参数做结构化存储（字段化），不切成文本片段，避免表格被切坏
- 合规文档和营销文案分索引存放，避免营销话术覆盖合规表述

查询层

- 口语归一化：「水光针、打针、医美」统一映射到「医美对比」实体
- 多问题拆成子查询：「敏感肌先用哪个 + 发货多久 + 推荐搭配」拆成三个，分别路由到 RAG、API、推荐 Skill
- 注入用户特征：用户自述「敏感肌」后，作为后续检索条件一起带上

召回层

- 向量 + BM25 混合召回，成分名（乙醇、玻色因）这类精确词靠 BM25 命中
- 元数据前置过滤：先按 sku 过滤，再检索，杜绝「孚玻因」这类跨产品召回
- 高风险问题适当调大 Top K，扩大候选池，避免关键禁忌 chunk 漏召回

重排层

- cross-encoder 做相关性排序，识别问题里的限定条件（「敏感肌」+「晶露」）
- 叠加业务权重：合规文档 > 营销文案；命中风险标签的 chunk 加分
- 冲突检测：召回结果里同时出现「含乙醇」和「敏感肌可放心用」时，标记冲突，以成分事实为准

12.4 推理侧角度：Context、采样参数、置信度、自洽

Context 组装

- Context = system 指令 + 用户问题 + 会话历史 + Observation。把本会话已确认的关键事实（如「晶露含乙醇」）作为会话状态保留，后续回复必须与之一致，解决 #8 前后矛盾
- 会话变长时做压缩：工具调用过程丢弃、只留结果；早期对话做摘要，但当前问题和关键事实不压缩

采样参数按风险设置

风险等级	问题类型	Temperature	置信度阈值	低于阈值
低	物流、礼盒内容	0.3–0.5	0.7	正常回答并附说明
中	普通成分、使用方法	0.1–0.3	0.85	只输出 RAG 原文

风险等级	问题类型	Temperature	置信度阈值	低于阈值
高	敏感肌、孕期、对比医美	0–0.1	0.9	转人工

- 低 temperature 同时解决 #3「同一问题多套说法」：高风险问题只输出唯一的合规答案
- **置信度联动**：如果召回结果没覆盖用户的核心场景（如「敏感肌 + 含乙醇」），即使单条分数高也判为置信不足，禁止模型用自带知识补全
- **自洽校验**：高风险问题生成多个候选，结论不一致时不输出，转人工

Prompt

- system 指令写明规则：不得宣称美白、不得与医美对比、不得使用「放心使用、一定、精准解决」
- few-shot 放入 3–5 条核验过的标准问答，例如「敏感肌问含酒精产品」的正确示范

12.5 护栏与兜底角度：Guardrail 和 Harness

输入护栏：识别高风险关键词（水光针、孕妇、过敏、泛红），给请求打风险等级，决定后续路由和参数

输出护栏

- 违禁词拦截：绝对化、承诺性用语（精准解决、一定、根治、放心使用、无刺激）命中则改写或拦截
- 引用溯源校验：回答里的成分和功效必须能在当前 SKU 的 chunk 里找到出处，找不到的（如「孚玻因」）删除
- 功效边界校验：功效表述不超出包装和备案范围；美白类问题改写为「本品不是美白产品，主要作用是提亮和淡纹」

Harness 兜底

- 大模型调用设超时（如 10 秒）和有限次重试；仍失败则返回兜底话术并转人工，解决 #7「思考已停止」
- 高频固定问答（礼盒内容、含酒精清单）放 Redis 热缓存，直接返回，不经过生成，降低延迟和失败率
- 全链路日志：记录意图、召回 chunk、置信度、护栏结果，方便 badcase 回溯

12.6 训练侧角度：SFT / DPO（可选，问题持续存在再做）

先用 RAG、Prompt、护栏解决；只有某类错误反复出现时才考虑轻量训练，不动基座模型。

- **意图识别 SFT / LoRA**：用「医美对比、敏感肌、孕期」等高风险问法的标注数据微调意图分类器，修正 #1 的分类错误
- **DPO 合规偏好对齐**：同一问题准备一好一坏两条回答，例如
  - chosen：「晶露含乙醇，敏感肌建议先耳后试用，或先从不含乙醇的乳液开始」
  - rejected：「成分安全，敏感肌可以放心使用」

  让模型偏好诚实、合规的说法
- 训练数据来源：本次评测和线上抽检得到的 badcase

12.7 评测与数据闭环角度：评测中台 + 数据中台

评测中台（质量门禁）

- 数据集分三类：黄金集（本次 8 个问题的标准答案）、回归集（历史 badcase）、对抗集（同义改写、多问题混合、诱导式提问如「是不是和水光针一样」）
- 接入 CI/CD：知识库、话术、Prompt 或模型有更新时自动跑评测，未达标就拦截发布，并输出失败明细
- 用 LLM Judge + rubric 打分：事实正确、合规、前后一致、是否回答全部问题

指标	定义	目标
高风险合规率	医美对比 / 敏感肌 / 孕期问题回复合规的比例	100%
违禁词命中	每千次回复出现绝对化、承诺性用语次数	0
同问一致率	同一问题问 3 次，结论一致的比例	⩾ 95%
引用可溯源率	回答中的成分、功效能在 SKU 资料中找到出处的比例	⩾ 98%
无回复率	出现「思考已停止」等空回复的比例	< 0.5%
多问题覆盖率	一条消息含多个问题时全部得到回应的比例	⩾ 90%

数据中台（数据底座）

- 提供评测用的真实 query、对话日志、用户反馈和差评
- 评测产出的 badcase 回流到数据中台，打标签后补充进知识库、few-shot 样例和训练数据，形成迭代闭环

12.8 实施顺序

阶段	时间	做什么	解决的问题
止损	1 周内	高风险意图专属路由；输出护栏违禁词拦截；Harness 超时兜底；#1、#8 改为合规回复	P0、P1、#7
修 RAG	2–4 周	SKU 元数据和风险标签；元数据前置过滤；重排业务权重和冲突检测；风险分级 temperature 和置信度阈值	#8 根因、#3、串产品
建闭环	1–2 个月	查询拆分；会话事实记忆；评测中台回归集接入 CI/CD；badcase 回流	#2、多问题、防止复发
视情况	之后	意图识别 LoRA；DPO 合规偏好对齐	反复出现的同类错误

说明：以上方案基于黑盒测试结果推断，假设系统为「意图识别 + 预设话术为主、大模型生成为辅」的架构，具体实现需结合内部系统确认。优先级按「合规风险 > 用户安全 > 体验 > 转化」排序。